

ECON-520

Ciencia de Datos para Economía y Negocios Clases 9-11

Viktoriya Semeshenko
Sergio De Raco



<https://bit.ly/e520-2026C2-text-mining>



<https://bit.ly/e520-2026C2-text-mining>



Aplicaciones I: Introducción a Text Mining

Text Mining

¿Qué es **text mining**?

- [Wiki](#) dice:


Text mining, text data mining (TDM) or text analytics is the process of deriving high-quality **information** from **text**.

It involves "the discovery by computer of new, previously unknown information, by automatically extracting information from different written resources."

- [IBM](#) dice:


Text mining, also known as text data mining, is the process of transforming unstructured text into a structured format to identify meaningful patterns and new insights. You can use text mining to analyze vast collections of textual materials to capture key concepts, trends and hidden relationships.

Algunas áreas de TM:



Text Mining

- Introduction to tidytext




Frecuencia de palabras y documentos

Enfoques para tratar con las palabras muy frecuentes (alto tf , poco informativas)

- **stopwords**: quitarlas del análisis, pero alguna en algún doc puede ser muy informativas
- **frecuencia inversa de términos en documentos** (idf): combinado en $tf-idf$ (producto de ambos), un estadístico que mide la frecuencia de un término ajustado (ponderado) por cuán raro es su utilización en el corpus documental
- **Ley de Zipf (linguista)**: la frecuencia de aparición de una palabra es proporcionalmente inversa a su ranking (ley de potencias)

$$\text{frequency} \propto \frac{1}{\text{rank}}$$



tf-idf

- **tf** es la frecuencia del **término** t en un documento d del corpus
- **idf** es la frecuencia (inversa) de la proporción de **documentos** en que ocurre el **término** t , n_t , respecto del total N de documentos del corpus (en logs)
- **tf-idf** es el producto de ambos estadísticos y sirve para detectar palabras importantes que *no son demasiado comunes* en el corpus

$$\text{tf}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$$

$$\text{idf}(t, D) = \log \frac{N}{n_t}$$

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

Topic modeling

- [LDA](#) (Blei et al., 2003): modelo probabilístico de generación de tópicos en corpus de documentos
 - Supuestos
 - Todos los documentos son una mezcla de tópicos
 - Todos los tópicos son una mezcla de palabras
 - Problema: encontrar la combinación de palabras asociadas a cada tópico y a la vez while determinar la combinación de tópicos que describen cada documento
- Silge - Robinson (2017), chapter 6 - [Topic Modeling](#)

LDA

M documentos de un corpus

N palabras por documento

V diccionario de palabras del corpus

K tópicos

α parámetro de tópicos por doc

β parámetro de palabras por tópico


θ distribución Dir de tópicos por documento

φ distribución Dir de palabras por tópico

z_{ij} tópico por j-ésima palabra en documento i

w_{ij} palabra específica

Única variable observable!





Ejercicios

- Explorar y analizar estos textos con las rutinas vistas en clase
 - <http://mirrors.xmission.com/gutenberg/1/10/10-0.txt>
 - <https://ciudadseva.com/autor/julio-cortazar/cuentos/>
 - Libros en [Project Gutenberg](#) (paquete [gutenbergr](#))

Material + Referencias TM

Biblio de referencia

- [Text Mining](#) @Wikipedia
- Silge and Robinson (2017), [Text Mining with R: A Tidy Approach](#)
- Hastie, Tibshirani and Friedman (2017), [The Elements of Statistical Learning: Data Mining, Inference, and Prediction](#). (2nd edition, 12th printing)



Bonus

- [The Shape of Stories](#), [Kurt Vonnegut](#)
- [Unix for poets](#), Kenneth W. Church



Tarea 05 - Text mining

- Workflow de análisis de texto
 - Usar datos de páginas de [McKinsey Mind-the-gap](#) (disponibles [acá](#))
 - Siguiendo el workflow visto en clase basado en Tidytext, explorar y describir:
 - De qué se trata este corpus? Son comparables los documentos?
 - Aspectos destacados del corpus utilizado
 - Sentimiento de las notas utilizando diccionarios binarios y con graduaciones
 - Topic modelling para k=10 y k=15 tópicos
 - AVANZADO: Análisis de redes de bigrams
 - más frecuentes
 - con negaciones ([p.ej.](#): “NOT word”)

Deadline: mar 29-sep

Aplicaciones

- Silge - Robinson (2022), **Tidy Topic Modeling**
- Schweinberger (2022), **Network Analysis using R** (Shakespeare's Romeo & Juliet)

Referencia `igraph` y otros

- `igraph`
 - [Manual de referencia R](#)
 - [Cheat sheet](#)
- R tidyverse related packages
 - [ggraph](#)
 - [tidygraph](#)

Ejercicios

- Explorar y analizar estos textos con las rutinas vistas en clase
 - <http://mirrors.xmission.com/gutenberg/1/10/10-0.txt>
 - <https://ciudadseva.com/autor/julio-cortazar/cuentos/>
 - Libros en [Project Gutenberg](#) (paquete [gutenbergr](#))
 - [Scraping](#) de Mind the Gap @mckinsey ([ACA](#) el dataset scrapeado)